

기술적 지표 최적화와 ESN을 활용한 주가 예측 모델

201811705 문민중
202030467 김기환
202012037 오수현
202012483 정파랑

요약

본 연구는 금융 시계열 데이터의 비선형성과 노이즈 문제를 해결하고, 급변하는 시장 환경에 적응적으로 대응할 수 있는 고도화된 자동 매매 시스템을 제안한다. 이를 위해 CPM 알고리즘을 활용하여 시장의 미세한 등락을 제거하고 유의미한 추세 전환점을 포착하여 학습 데이터를 구축하였다. 또한, 유전 알고리즘을 도입하여 기술적 지표(MA, RSI, ROC)와 시계열 예측 모델인 ESN의 하이퍼파라미터를 최적화하였으며, 수익률 극대화와 최대 낙폭(MDD) 최소화를 동시에 달성할 수 있는 적합도 함수를 설계하였다. 나스닥 상장 기업을 대상으로 한 10년간의 데이터 실험 결과, 제안된 모델은 단순 보유(Buy & Hold) 전략이 손실을 기록하였을 때, 높은 확률로 더 적은 손실을 보거나 이익을 창출하여 탁월한 위험 관리 능력을 입증하였다. 비록 강한 상승장에서는 방어적 기제로 인해 시장 수익률보다 낮은 결과를 보이는 한계를 보였으나, 본 연구는 많은 금융 시장에서 안정적인 수익 창출과 하락장에 대한 위험 방어가 가능한 모델의 유효성을 확인하였다는 데 의의가 있다.

Keywords: Stock forecast, Critical Point Method, Technical analysis, Genetic Algorithm, Echo State Network, Expanding Window, Max Draw Down, eXtreme Gradient Boosting

1. 연구 배경

금융 시장은 비선형적이고 혼돈적인(Chaotic) 특성이 있어 예측이 매우 어려운 분야이다. 그럼에도, 주식 시장의 효율적인 매매 시점을 포착하여 수익을 극대화하려는 시도는 끊임없이 계속되고 있다. 최근에는 딥러닝(Deep Learning) 기술의 발전으로 LSTM, Transformer 등을 활용한 시계열 예측 연구가 활발하지만, 금융 데이터의 노이즈(Noise)와 비정상성(Non-Stationarity)은 여전히 큰 과제로 남아 있다.

기존의 주가 예측 연구들은 크게 두 가지 측면에서 한계를 가진다. 첫째, 레이블링(Labeling)의 문제이다. 단순히 n 일 후의 가격 상승과 하락을 예측하는 고정된 기간(Fixed Time Horizon) 방식은 시장의 파동과 추세 전환점을 정확히 반영하지 못한다. 주가는 시간의 흐름이 아닌 가격의 변동에 따라 추세가 결정되기 때문이다. 둘째, 입력 변수(Feature)의 경직성이다. Moving Average(MA), Relative Strength Index(RSI), Rate Of Change(ROC) 등 기술적 지표를 입력 변수로 사용할 때, 대다수의 연구는 RSI 14일, MA 20일 등과 같이 통상적인 파라미터를 고정적으로 사용한다. 그러나 시장의 상황은 수시로 변하므로, 고정된 파라미터는 변화하는 시장 국면에 적절히 대응하지 못하여 모델의 성능을 저하하는 원인이 된다.

이에 본 연구에서는 이러한 한계를 극복하기 위해 다음과 같은 알고리즘 기반의 트레이딩 시스-

템을 제안한다. 본 연구의 목적은 CPM(Critical Point Method)을 통해 시장의 노이즈를 필터링하고, 유전 알고리즘(Genetic Algorithm, GA)로 최적화된 기술적 지표를 ESN에 학습시킴으로써, 기존의 정적인 기술적 분석이나 단일 딥러닝 모델보다 우수한 수익률과 위험 대비 성과를 달성하는 데 있다. 이를 통해 급변하는 금융 시장 환경에서도 적응적으로 대응할 수 있는 자동 매매 시스템의 고도화 가능성을 제시하고자 한다.

본 논문의 구성은 다음과 같다. 2장에서는 기존 연구와 관련 기술을 개괄하고, CPM 기반 레이블 정의와 기술적 지표 최적화 방법을 설명, ESN 구조 및 GA 기반 하이퍼파라미터 탐색 과정을 기술한다. 3장에서는 본 연구에서 제안하는 트레이딩 모델의 전체 구조를 기술한다. 4장에서는 본 연구에서 제안한 트레이딩 모델의 주요 결과를 종합적으로 정리하고, 연구가 갖는 시사점을 논의한다. 또한 본 연구의 한계를 바탕으로 향후 개선이 필요한 방향과 후속 연구의 가능성을 제시함으로써 연구를 마무리한다.

2. 용어 정리

2.1 CPM

본 연구에서는 금융 시계열의 미세한 노이즈를 제거하고 주 추세(Major Trend)의 전환점을 포착하기 위해 CPM을 활용하여 학습 데이터를 구축하였다. CPM은 단순히 주가의 등락만을 고려하는 것

이 아니라, 파동의 진폭(Oscillation)과 지속 기간(Duration)을 동시에 고려하여 추세의 유의미성을 판단하는 알고리즘이다. 구체적인 절차는 다음과 같다. 우선 주가 시계열 데이터에서 모든 국소적 고점과 저점을 추출하여 초기 극점 집합(Critical Points)을 구성한다. 이후 인접한 두 극점 사이의 진폭과 기간이 사전에 설정한 임계값 P와 T(본 연구에서는 0.05, 5)를 초과하는지 검사한다.

$$(Osc_{ij} \geq P) \vee (Dur_{ij} \geq T)$$

인접한 두 극점 c_i 와 c_j 사이의 진폭(Osc_{ij})과 기간(Dur_{ij})에 대해서 위 식을 만족할 경우, 이를 유의미한 파동(Big)으로, 그렇지 않은 경우를 미미한 파동(Small)으로 분류한다. 이후 연속된 파동의 조합을 분석하여, 단순한 등락이나 일시적인 놀림목에 해당하는 변곡점은 노이즈로 간주하여 제거하고, 실제 추세가 반전되는 중요한 변곡점만을 최종 매매 시점으로 확정한다. 최종적으로 선별된 고점은 매도 시점(+1), 저점은 매수 시점(-1)으로 레이블링하여 모델의 학습 데이터(Ground Truth)로 활용한다[1].



[그림 1] 일일 주가 차트와 CPM

[그림 1]을 보면 파란색 실선은 원본 일간 주가(Daily Close Price)를 나타내며, 주황색 실선은 CPM 알고리즘($P=0.05$, $T=5$)을 통해 추출된 유의미한 극점(Critical Points)들을 연결한 추세선이다. 주가 그래프(파란색)은 매일매일의 미세한 등락(Noise)이 모두 포함되어 있어 선이 거칠고(Jagged) 불규칙하다. 반면 CPM 데이터 그래프(주황색)는 미세한 등락은 무시하고, 의미 있는 고점과 저점(Critical Points)만을 직선으로 연결한 형

태이다. 즉, 자잘한 변동 다 무시하고, 여기서 샀다가 저기서 팔았으면 최고였다“는 정답지(Label) 역할을 한다.

2.2 기술적 분석

기술적 분석은 금융 시장에서 발생하는 가격 변동과 거래량 등 과거 시장 데이터를 기반으로 미래의 가격 변동을 예측하는 분석 기법이다. 기술적 분석은 시장 가격이 모든 정보를 반영한다는 가정과 가격은 추세를 가지고 움직인다는 가정, 역사적 패턴은 반복된다는 가정에 기반한다. 이러한 특징 때문에 TA(Technical Analysis, TA)는 수학적 모형과 알고리즘 기반 전략과 상당히 높은 결합성을 가지고 있다. 이 때문에 알고리즘 트레이딩 분야에서 널리 사용된다.

기술적 분석의 핵심 구성 요소는 '지표(Indicator)'이다. 지표는 가격 데이터(시가, 고가, 저가, 종가)와 거래량을 기반으로 산출되고, 추세(Trend), 모멘텀(Momentum), 변동성(Volatility), 거래량(Volume) 등 다양한 시장 상황을 수치적으로 표현할 수 있게 한다. 대표적으로 사용되는 지표에는 MA, RSI, ROC 등이 있다. 이러한 지표들은 추세 전환이나 과매수, 과매도 상태를 식별하여 매수, 매도 신호 생성 등에 활용된다.

본 연구에서는 총 3가지 기술적 분석의 주요 지표(MA, RSI, ROC)를 대상으로 유전 알고리즘을 적용하여 최적의 파라미터 조합을 탐색하고, 이를 통해 안정적이고 검증된 매수, 매도 신호를 생성하였다. 이후 생성된 기술적 신호들은 ESN 기반의 시계열 예측 모델과 결합하여 매수, 매도 시점 예측의 성능 향상에 활용되었다.

2.3 유전 알고리즘

유전 알고리즘은 생물학적 진화 과정에서 관찰되는 자연 선택과 유전적 변이의 개념을 모방하여 최적해를 탐색하는 확률적 최적화 기법이다. John Holland(1975)에 의해 체계적으로 정립된 이후, 복잡한 비선형 문제나 탐색 공간이 매우 넓은 문제에서도 효과적으로 활용되고 있다.

GA는 문제의 후보 해(solution)를 개체로 정의하고, 개체를 구성하는 파라미터를 유전자로 간주하여 하나의 해를 염색체 형태로 표현한다. 알고리즘은 초기 세대에서 무작위로 생성된 개체 집단을

기반으로 시작하며, 각 개체의 성능은 적합도 함수(Fitness Function)를 통해 평가된다. 적합도는 해당 해가 문제를 얼마나 효과적으로 해결하는지를 측정하는 지표로, 선택, 교차, 돌연변이 등의 연산 과정에서 핵심적인 역할을 한다. GA의 진화 과정은 다음과 같은 단계로 진행된다. 첫째, 선택 단계에서는 높은 적합도를 가진 개체가 다음 세대에 생존하거나 부모로 선택될 확률이 높아진다. 일반적으로 룰렛 휠 선택(Roulette Wheel Selection), 순위 기반 선택(Rank Selection), 또는 토너먼트 선택(Tournament Selection) 기법이 사용된다. 둘째, 교차 단계에서는 선택된 두 개체의 유전자를 교환하여 새로운 자손 개체를 생성한다. 이는 탐색 공간을 효율적으로 확장하는 역할을 하며, 단일 지점 교차(one-point crossover), 균등 교차(uniform crossover) 등이 대표적이다. 셋째, 돌연변이 단계에서는 일정 확률로 유전자 값이 무작위로 변형되며, 이는 집단이 특정 지역 최적해에 빠지는 것을 방지하여 탐색의 다양성을 유지한다.

이와 같은 과정을 여러 세대에 걸쳐 반복하면 적합도가 높은 개체가 점차 많아지며, 결과적으로 전역 최적해에 가까운 해를 발견할 가능성이 증가한다. GA는 미분 정보가 요구되지 않고 비선형, 비연속적 함수에도 적용 가능하다는 점에서 금융 데이터 분석, 기술적 지표 최적화, 신호 최적화, 신경망 하이퍼파라미터 탐색 등 다양한 분야에서 널리 활용되고 있다.

본 연구에서는 GA를 활용하여 MA, RSI, ROC 등 기술적 지표의 최적 파라미터를 탐색하고, 이를 기반으로 매매 신호를 자동 생성하였다. GA는 세대별로 파라미터 조합을 진화시키며 최적화된 기술적 지표 조합을 도출하였다. 이러한 방식은 전통적인 수동 파라미터 선택보다 더 넓은 탐색 공간을 고려할 수 있으며, 비선형적이고 복잡한 시장 데이터 패턴에 효과적으로 대응할 수 있다는 장점이 있다.

또한 본 연구에서는 토너먼트 선택(Tournament Selection) 기법을 사용하여 세대마다 부모 개체를 선정하였다. 토너먼트 선택은 매 세대마다 모집단(Population)에서 무작위로 k 개의 개체를 선택한 뒤, 이들 중 가장 높은 적합도(Fitness)를 가진 개체를 부모로 선택하는 방식이다. 본 구현에서는 $k=3$ 으로 설정된 3-토너먼트 선택을 적용하여, 무작위성과 선택 압력(selection pressure)을 적절히

균형 잡았다. 즉, 매 세대마다 여러 그룹의 3개 개체가 무작위로 구성되고, 각 그룹 내에서 최적 개체가 부모로 선택되며, 이러한 절차를 통해 필요한 수만큼의 부모를 확보한다. 이 방식은 우수한 해를 안정적으로 선택하면서도 다양한 해가 탐색 될 수 있도록 보장하여 GA의 탐색 효율을 향상한다.

2.3 ESN

ESN은 순환신경망(RNN)의 한 종류로, 빠르고 가벼운 시계열 예측 모델이다. 일반적인 RNN, LSTM은 복잡한 가중치 학습 과정이 필요하지만, ESN은 은닉층의 가중치를 학습하지 않고 그대로 고정시킨다는 차별점이 있다. 모델이 학습하는 부분은 출력층뿐이기 때문에 계산 비용이 낮고, 금융 데이터처럼 변동성이 큰 시계열에서도 빠르게 학습하면서도 일정 수준의 예측 성능을 보여준다.

ESN의 핵심 요소는 ‘저수지(reservoir)’라 불리는 비선형 은닉층이다. 입력 데이터가 이 저수지 안에서 여러 뉴런을 통해 복잡한 형태로 변환되며, 이러한 변환 결과는 시계열 패턴(추세 변화, 반복 패턴 등)을 풍부하게 표현하는 역할을 한다. ESN은 이 과정을 통해 입력된 기술적 지표나 가격 데이터의 시간적 관계를 효과적으로 반영할 수 있다.

ESN이 안정적으로 동작하려면 저수지 내부 연결이 무작위이더라도 시간이 지나면 입력에 의해 상태가 결정되고, 초기값의 영향은 사라져야 한다. 이러한 성질을 ‘Echo State Property’라고 한다. 이 조건을 만족하면 ESN은 예측에 적합한 동적 표현을 생성할 수 있다.

본 연구에서는 MA, RSI, ROC 등 기술적 지표를 기반으로 유전 알고리즘(GA)을 사용해 최적 파라미터를 찾은 뒤, 해당 지표들로 생성된 신호를 ESN의 입력으로 사용하여 매수·매도 시점을 예측하였다. ESN은 기술적 지표가 반영한 시장 정보를 시계열 관점에서 해석하여 향후 가격 움직임을 판단하는 데 활용되었다.

3. 학습 방법

본 모델에서는 나스닥(NASDAQ) 상장 기업 10개에 대하여, 각각의 주식에 대한 총 10년(2015.07.22~2025.07.21)에 대한 일간 주가 데이터를 yfinance 라이브러리를 사용하여 획득하고,

Train, Validation, Test 데이터를 분리하였고, 시계열 데이터의 특성을 반영한 확장 윈도우(Expanding Window) 방식의 롤링 포워드 교차 검증을 수행하였다. Train 데이터는 기술적 지표의 파라미터를 최적화하기 위해 사용하였고, Validation 데이터는 ESN의 파라미터를 최적화하기 위해 사용하였다. 구체적인 폴드의 구성은 아래의 표와 같다.

폴드	학습 및 검증 기간	테스트 기간
1	2015-07-22 ~ 2020-07-17	2020-07-20 ~ 2021-07-16
2	2015-07-22 ~ 2021-07-16	2021-07-19 ~ 2022-07-15
3	2015-07-22 ~ 2022-07-15	2022-07-17 ~ 2023-07-17
4	2015-07-22 ~ 2023-07-17	2023-07-18 ~ 2024-07-16
5	2015-07-22 ~ 2024-07-16	2024-07-17 ~ 2025-07-21

[표 1]

해당 모델의 학습에 사용한 기술적 지표는 MA, RSI, ROC에서 생성한 -1, 0, 1로 구성된 매수매도 신호를 사용하였다. 각 기술적 지표의 파라미터를 유전 알고리즘으로 최적화하였다. 최적화된 파라미터를 통해 구한 기술적 지표에서 생성한 매매 신호와 주가의 추세 강도를 정량화하기 위한 장단기 기울기, 전일 대비 주가 변화율을 모델의 학습에 사용하였다. 특히 장단기 기울기는 주가 수준에 따른 스케일 차이를 없애기 위해 주가 대비 백분율로 변환하였으며, 모든 입력 변수는 모델 학습의 효율성을 위해 표준화 과정을 거쳐 입력하였다.

ESN의 파라미터에서 Reservoir의 수는 300으로 고정하고, ESN 모델에서 결정적인 영향을 미치는 파라미터인 Spectral Radius, Sparsity, Input Scaling과 모델의 생성하는 매매 신호를 판별하기 위한 양수 임계값인 Buy Threshold, Sell Threshold를 유전 알고리즘으로 최적화하였다. ESN 모델의 출력값이 -Buy Threshold보다 작으면 매수, Sell Threshold보다 높으면 매도 포지션을 취하도록 하였다.

ESN 파라미터를 유전 알고리즘으로 최적화하는 과정에서 모델의 적합도를 평가하기 위한 목표 함

수는 수익률을 극대화하되 동시에 최대 낙폭(Max Draw Down, MDD)을 최소화하는 것을 목표로 하였고, 그 식은 다음과 같다.

$$(Return) \times (SQN) / (|MDD|^{0.25})$$

위 식을 사용함으로써, 단순히 수익률만 높은 모델보단 손실 또한 적게 보는 모델에게 더 높은 적합도를 받을 수 있도록 설계하였다.

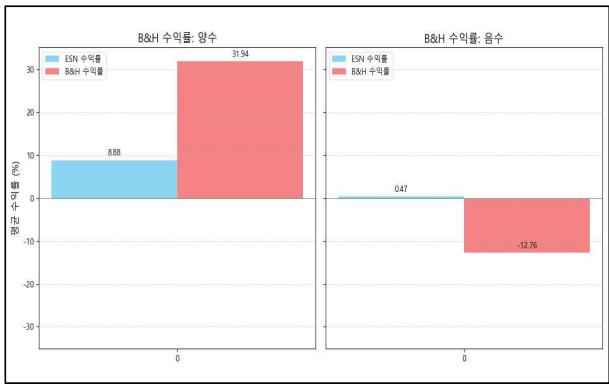
4. 논의 및 결론

4.1 모델의 전략적 목표 분석

본 연구에서 제안한 GA-TA-ESN 결합 모델은 단순한 수익률의 극대화보다는 위험 대비 시스템의 성능 안정성을 우선시하는 방어적 기제로 학습되었으며, 이에 따라 고위험 구간에서의 적극적인 매매를 회피하는 특성을 나타냈다. 이러한 방어적 전략의 결과, 단순 보유(B&H) 전략 대비 전체 평균 수익률 측면에서는 다소 낮은 성과를 기록했지만 (B&H 전체 평균 21.36% vs ESN 전체 평균 6.94%), 하락장 위험 관리 측면에서 탁월한 성과를 보였다.

모델의 방어적 특성은 B&H 전략이 음의 수익률을 기록한 구간(하락장, 총 14개 Fold)에서 명확히 드러난다. [그림 2]에서 볼 수 있듯이, ESN 모델은 해당 Fold 평균에서 B&H 대비 우수한 성과를 달성하며 탁월한 하락장 방어 능력을 입증하였다. 이는 시장의 변동성이 확대되거나 하락 추세가 지속될 때 본 모델의 강점이 들어난다는 것을 보여준다.

ESN 모델은 시장이 10% 이상의 큰 폭으로 하락하는 위험 구간에서도 손실 폭을 크게 줄이는 것을 넘어 수익(양의 값)으로 전환시키는 성공 사례를 보였. 예를 들어, B&H 전략이 -14.62%의 손실을 기록하는 동안 ESN 모델은 7.83%의 수익을 달성하며 위험 대비 성과를 입증하였고 시장이 -6.32% 하락하는 상황에서도 ESN 모델은 20.57%의 고수익을 창출하며 B&H 대비 26.89%의 초과 수익을 기록하였다. 이는 ESN이 위험 조정 적합도 함수를 통해 하락 위험을 감지하고 공격적인 포지션 보유를 회피하여 하락장 속에서 유의미한 반전 지점을 포착했음을 의미한다.



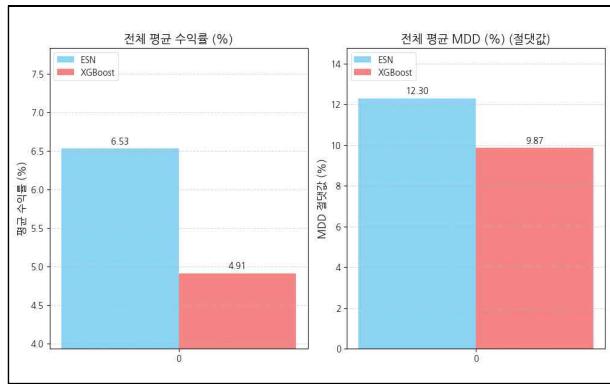
[그림 2] B&H 수익률 부호별 ESN vs B&H 평균 수익률 비교

4.2 제안된 모델과 XGBoost와의 비교

제안 모델인 ESN이 최선의 성능을 내는지 알아보기 위해 XGBoost 모델과의 비교 분석을 진행했다. XGBoost(eXtreme Gradient Boosting)는 Chen & Guestrin (2016)에 의해 제안된 확장 가능한 트리 부스팅 시스템이다[2]. 이 모델은 병렬 처리와 효율적인 메모리 사용으로 대규모 데이터에서 매우 빠르고 정확한 결과를 제공하며, 복잡하고 비선형적인 주가 움직임 패턴을 높은 정확도로 분류하는 능력이 입증되어 비선형 시계열 예측의 강력한 대안으로 간주 된다.

본 연구의 제안 모델인 ESN과 대표적인 머신러닝 모델인 XGBoost의 성능을 비교 분석한 결과, ESN은 평균 수익률, MDD 관리, 하락장 방어 성공률 등 주요 평가지표 전반에서 XGBoost 대비 우위를 점하며 최종적으로 가장 우수한 모델임이 입증되었다.

[그림 3]에서 볼 수 있듯이, ESN은 XGBoost 대비 더 높은 전체 평균 수익률(6.53% vs 4.91%)을 기록하여 안정적인 수익 창출 능력을 보였다. 이는 ESN의 리저버 컴퓨팅 구조가 GA로 최적화된 TA를 효과적으로 학습하여 비선형적 시장 변화에 안정적으로 대응했기 때문이다.



[그림 3] ESN vs XGBoost 종목 전체 평균 비교

MDD는 특정 기간 동안 최고점에서 최저점까지의 최대 손실 폭을 의미하는 위험 지표이며, 값이 낮을수록 투자 위험도가 낮고 안정적인 성과를 나타낸다. MDD를 절댓값으로 변환하여 위험도로 판단했을 때, ESN의 평균 MDD는 12.30%로 9.87%를 기록한 XGBoost 대비 2.43% 높은 수치를 기록했다. 즉, XGBoost가 더 낮은 최대 손실 폭을 기록하여 위험 관리 자체 측면에서는 우위에 있음을 보였으나, ESN은 더 높은 수익을 창출하면서도 12.30%의 MDD를 유지하여 위험 대비 수익 관점에서 우수성을 확보한다.

이러한 ESN의 방어적 우위는 하락장 수익 전환 능력에서 명확하게 드러난다. 두 모델 모두 B&H 손실 구간에서 100%의 방어율을 보였으나, XGBoost가 손실 방어에 그친 구간을 ESN은 수익(양의 값)으로 전환시키는 등 수익 창출 잠재력 면에서 압도적인 성과를 보였다. 따라서 GA로 최적화된 입력 변수와 위험 조정 적합도 함수를 적용한 ESN 모델이 종합적인 성능과 안정성 측면에서 비교 우위를 가지는 것으로 판단된다.

4.3 연구의 한계 및 향후 연구 방향

본 연구에서 제안된 GA-TA-ESN 모델은 위험 조정 수익률(Risk-adjusted Return)의 극대화를 최우선 목표로 설계되었으나, 이로 인해 MDD 억제에 과도한 가중치가 부여되면서 강력한 상승 추세(Bull Market)에서 단순 보유(B&H) 전략 대비 수익 기회를 충분히 포착하지 못하는 구조적 한계를 드러냈다. 이는 시장 국면(Regime)의 동적인 변화와 무관하게 일관된 위험 회피 성향을 유지하도록 학습된 결과로 판단된다.

이러한 한계를 극복하고 모델의 실전 효용성을

제고하기 위해, 향후 연구는 데이터 전처리, 모델 최적화, 그리고 전략 실행의 세 가지 차원에서 입체적인 고도화가 요구된다. 우선, 데이터 전처리 단계에서는 고정된 파라미터 대신 시장의 변동성 변화를 즉각적으로 반영할 수 있는 동적인 CPM 임계값 알고리즘을 도입하여 레이블링의 정교함과 학습 데이터의 품질을 개선해야 한다. 이어 모델 학습 단계에서는 시장을 상승, 하락, 횡보 국면으로 사전 분류하고 각 국면에 따라 수익률과 MDD에 대한 가중치를 유연하게 조절하는 적응형 적합도 함수(Adaptive Fitness Function)를 개발함으로써, 시장 상황에 따라 모델의 성향을 능동적으로 변화시킬 필요가 있다. 마지막으로, 전략 실행 단계에서는 모델이 수익 추구에 집중할 수 있도록 트레일링 스탑(Trailing Stop)과 같은 사후적 위험 제어 메커니즘을 결합하는 이원화된 전략을 모색하여, 상승장에서의 소외 현상을 방지함과 동시에 시스템적 안정성을 확보하는 방향으로 연구를 확장해야 할 것이다.

5. 결론

본 연구는 CPM을 활용한 추세 전환점 기반 레이블링, 유전 알고리즘에 의한 기술적 지표의 파라미터 최적화, 그리고 ESN의 시계열 데이터 예측 구조를 통합하여 주식 시장에서의 매매 및 매도 시점 예측 모델을 제안하고 그 수익률을 비교 분석하였다. CPM을 통해 주가의 미세 변동으로 발생하는 노이즈를 체계적으로 제거함으로써 학습에 활용되는 추세 전환점의 신뢰도를 확보하였고, GA를 통해 MA, RSI, ROC 지표의 하이퍼파라미터 최적화를 통해 정적인 기술적 지표가 갖는 한계를 완화하였다. 이러한 전처리 및 신호 생성 과정 위에 ESN을 결합한 모델은 시계열 데이터의 비선형적, 동적 특성을 효과적으로 반영하여 특정 시장 유형에서 안정적인 예측 성능을 보였다.

종합적으로, 본 연구는 CPM-GA-ESN으로 구성된 통합적 매매 시점 예측 체계가 변동성이 높은 금융 환경에서도 유의미한 실효성과 안정성을 확보할 수 있음을 실증적으로 제시하였다. 제안된 모델은 자동화된 매매 전략 설계, 리스크 관리 중심의 포트폴리오 구축, 알고리즘 트레이딩 시스템 고도화 등 다양한 금융 응용 분야에서 활용 가능성을 가지며, 향후 연구를 통해 그 예측력과 적응성이

더욱 확장될 것으로 기대된다.

참고문헌

- [1] D. Bao, "A generalized model for financial time series representation and prediction," *Applied Intelligence*, vol. 29, pp. 1-11, 2008.
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794). ACM.